Glycine Vision: Sistema de Triaje Fitosanitario Digital para Detección de Enfermedades en Soya

Glycine Vision: Digital Phytosanitary Triage System for Soybean Disease Detection

Alejandro Ramirez Vallejos
Estudiante de Ingeniería de Software
Universidad Católica Boliviana, sede
Santa Cruz
https://orcid.org/0009-0009-1517-6838

Recibido: 22/04/2026

Resumen

El objetivo de esta investigación fue desarrollar y evaluar un sistema de triaje fitosanitario digital denominado Glycine Vision, orientado a la detección y clasificación de enfermedades foliares en el cultivo de soya (Glycine max) en Santa Cruz, Bolivia. Se implementó un enfoque cuantitativo con diseño experimental aplicado, basado en aprendizaje profundo mediante transfer learning con arquitectura MobileNet a través de la plataforma Teachable Machine de Google. Se construyó un pipeline de preparación de datos que integró siete fuentes públicas de imágenes, incluyendo ASDID (9,981 imágenes), MH-SoyaHealthVision y PlantVillage, con un dataset inicial de 34,217 imágenes que, tras filtrado de calidad y deduplicación por hash MD5, quedó reducido a 5,745 para entrenamiento y 550 para prueba. El sistema emplea dos modelos en cascada: el Modelo 1 clasifica soya sana vs. enferma (1,000 imágenes/clase) y el Modelo 2 identifica el tipo de patógeno en cinco categorías (bacterianas, fúngicas, roya, virales y plagas/insectos) con 749 imágenes/clase. La evaluación sobre 550 imágenes de prueba arrojó una exactitud del 98.00% para el Modelo 1 (F1: 0.9804) y del 95.09% para el Modelo 2 (F1 promedio: 0.9472). En conclusión, Glycine Vision demostró ser una herramienta accesible para el diagnóstico fitosanitario, con potencial de integración en dispositivos móviles para apoyar a productores soyeros de Santa Cruz.

Palabras clave: deep learning, Teachable Machine, MobileNet, enfermedades de soya, clasificación de imágenes, triaje fitosanitario, transfer learning

Abstract

The objective of this research was to develop and evaluate a digital phytosanitary triage system called Glycine Vision, designed for the detection and classification of foliar diseases in soybean (Glycine max) crops in Santa Cruz, Bolivia. A quantitative approach with an applied experimental design was implemented, supported by deep learning through transfer learning with a MobileNet architecture using Google's Teachable Machine platform. A data preparation pipeline was built that integrated seven public image sources, including ASDID (9,981 images), MH-SoyaHealthVision, and PlantVillage, resulting in an initial dataset of 34,217 images which, after quality filtering and MD5 hash deduplication, was reduced to 5,745 for training and 550 for testing. The system employs two cascading models: Model 1 classifies healthy vs. diseased soybeans (1,000 images/class) and Model 2 identifies the pathogen type across five categories (bacterial, fungal, rust, viral, and pests/insects) with 749 images/class. The evaluation on 550 test images yielded an accuracy of 98.00% for Model 1 (F1: 0.9804) and 95.09% for Model 2 (average F1: 0.9472). In conclusion, Glycine Vision proved to be an accessible tool for phytosanitary diagnosis, with potential for integration into mobile devices to support soybean producers in Santa Cruz.

Keywords: deep learning, Teachable Machine, MobileNet, soybean diseases, image classification, phytosanitary triage, transfer learning

Introducción

La soya (Glycine max) es uno de los cultivos de mayor importancia económica en Santa Cruz, Bolivia, departamento que concentra el 80% de la producción nacional. Las enfermedades foliares como la roya asiática (Phakopsora pachyrhizi), el mosaico viral y la mancha bacteriana pueden causar pérdidas de entre el 20% y el 80% del rendimiento cuando no se detectan a tiempo. La identificación oportuna de patógenos es, por tanto, una necesidad crítica para los productores de la región.

Los métodos tradicionales de diagnóstico dependen de agrónomos o análisis de laboratorio, lo que los hace costosos, lentos y poco accesibles para pequeños productores. Frente a este problema, la visión por computadora y el aprendizaje profundo han demostrado ser alternativas efectivas. Mohanty, Hughes y Salathé (2016) mostraron que redes neuronales convolucionales entrenadas en el dataset PlantVillage pueden superar el 99% de exactitud en condiciones controladas. Trabajos más recientes validan el uso de MobileNet (Howard et al., 2017) en dispositivos con recursos limitados, con precisiones de entre 92% y 99% (Chen et al., 2020; Elfatimi et al., 2022).

Sin embargo, la brecha entre el rendimiento en condiciones de laboratorio y el desempeño en campo real es un desafío conocido en la literatura (Bevers et al., 2022). Para reducir la brecha, Barbedo (2018) señala que combinar fuentes de datos diversas es más importante que el volumen total de imágenes. En este contexto, la plataforma Teachable Machine de Google (Carney et al., 2020), que utiliza MobileNet con transfer learning, ha sido validada como herramienta científicamente válida para clasificación de enfermedades en plantas, con exactitudes de hasta 99.42% en imágenes de campo (Shrivastava et al., 2026; Malahina et al., 2024).

El presente trabajo es resultado del examen de la asignatura de Inteligencia Artificial para la carrera de Ingeniería de Software, nivel licenciatura, en la Universidad Católica Boliviana, sede Santa Cruz. El objetivo fue desarrollar y evaluar Glycine Vision, un sistema de triaje fitosanitario digital de dos etapas para la detección de enfermedades foliares en soya desde dispositivos móviles.

El código fuente del proyecto se encuentra disponible en GitHub (https://github.com/alejandroramirezucb/glycine-vision-dss). El conjunto de datos curado (tanto para entrenamiento como para pruebas) está disponible en Hugging Face bajo el identificador alejandroramirezucb/soybean_image_dataset.

Metodología

Se adoptó un enfoque cuantitativo con diseño experimental aplicado. El desarrollo del sistema siguió un pipeline de cuatro etapas: (1) recopilación e integración de datasets de múltiples fuentes, (2) filtrado de calidad por resolución y canales de color, (3)

deduplicación por hash MD5, y (4) muestreo estratificado para construir los conjuntos de entrenamiento y prueba.

Recopilación y construcción del dataset

Se integraron siete fuentes públicas de imágenes de hojas de soya. La Tabla 1 resume las fuentes, el número de imágenes aportadas y su licencia.

Tabla 1 Fuentes de datos utilizadas para el entrenamiento de los modelos.

Dataset / Fuente	N.° imágenes	Clases	Licencia	Referencia
PlantVillage (soya sana)	6,096	1 (sana)	CC0 1.0	Hughes & Salathé, 2015
ASDID – Auburn University	9,981	8 enf. + sana	CC0 1.0	Bevers et al., 2022
MH-SoyaHealthVision	5,680	6 clases	CC BY 4.0	Mendeley, 2024
Kaggle-sivm205	≈1,100	10 enf.	CC BY 4.0	Kaggle
India Soyabean Dataset	3,363	6 clases	CC BY 4.0	Kotwal et al., 2024
Kaggle-maeloisamignoni	5,514	2 (plagas)	CC BY 4.0	Kaggle
Kaggle-vaishaligbhujade	≈250	3 clases	CC BY 4.0	Kaggle

Nota. *Todas las fuentes tienen licencia abierta que permite uso académico y redistribución.*

Las imágenes de soya sana se obtuvieron de dos fuentes complementarias para reducir el domain shift: PlantVillage (fondo controlado) y el subconjunto Healthy del ASDID (campo real). Las enfermedades se agruparon en cinco categorías según el tipo de patógeno, siguiendo la clasificación propuesta por Rani y Gowrishankar (2023): bacterianas, fúngicas, roya, virales y plagas/insectos.

Filtrado de calidad y deduplicación

El pipeline aplicó tres filtros secuenciales a cada imagen: (1) verificación de apertura válida con PIL, (2) resolución mínima de 224×224 píxeles, y (3) modo de color RGB. La

deduplicación se realizó mediante hash MD5 sobre el contenido binario de cada archivo, eliminando imágenes exactamente iguales entre fuentes. El balanceo se implementó con semilla fija (seed=42) para reproducibilidad, con límites de 1,000 imágenes/clase para entrenamiento y 100 imágenes/clase para las pruebas. Esta práctica está respaldada por Nazki et al. (2020) y Abade et al. (2023), quienes documentan mejoras de 10-20% en rendimiento al equilibrar clases en datasets desbalanceados. Este proceso redujo el dataset inicial de 34,217 imágenes a 5,745 para entrenamiento y 550 para prueba.

Entrenamiento de modelos

Se desarrollaron dos modelos en cascada mediante Teachable Machine de Google, que utiliza MobileNet con transfer learning como arquitectura subyacente (Carney et al., 2020). La Tabla 2 detalla los hiperparámetros utilizados en cada modelo.

Tabla 2 Hiperparámetros de entrenamiento de los modelos.

Hiperparámetro	Modelo 1 (Sana/Enferma)	Modelo 2 (Tipo Patógeno)
Arquitectura base	MobileNet + transfer learning	MobileNet + transfer learning
Épocas	60	70
Tamaño de lote	16	16
Tasa de aprendizaje	0.00001	0.00001
Imgs. entrenamiento / clase	1,000	749
Clases	2 (sana, enferma)	5 tipos de patógeno
Resolución de entrada	224 × 224 px	224 × 224 px

Nota. *Ambos modelos utilizan MobileNet preentrenado en ImageNet con transfer learning.*

El Modelo 1 determina si una imagen corresponde a soya sana o enferma. Si el resultado es enferma, el Modelo 2 clasifica el tipo de patógeno en una de las cinco categorías. Este proceso en cascada permite asignar tratamientos diferenciados según el tipo de patógeno, siguiendo el enfoque propuesto por Rani y Gowrishankar (2023) y Park et al. (2023).

Evaluación

La evaluación se realizó sobre un dataset de prueba construido mediante el script prepare_dataset.py con imágenes no utilizadas en el entrenamiento. Para garantizar la comparabilidad entre clases, se estableció un máximo de 100 imágenes de prueba por clase. Tras el balanceo de clases, se obtuvo un total de 100 imágenes por clase para el Modelo 1 y 70 imágenes por clase para el Modelo 2, lo que resultó en 200 imágenes totales para el primero y 350 para el segundo. Las métricas evaluadas fueron: exactitud (accuracy), precisión, recall (recuperación) y puntuación F1.

Resultados y discusión

Modelo 1: Clasificación Soya Sana vs. Enferma

La Tabla 3 muestra los resultados de evaluación del Modelo 1. El modelo alcanzó una exactitud global del 98.00%, con un F1-Score de 0.9804 para la clase enferma. El recall perfecto de 1.0000 en soya enferma es especialmente relevante en un sistema de triaje, dado que los falsos negativos (plantas enfermas clasificadas como sanas) representan el error de mayor costo agronómico.

Tabla 3 Métricas de evaluación del Modelo 1 (Soya Sana vs. Soya Enferma).

Clase	Imgs. test	Accuracy	Precisión	Recall	F1-Score
Soya Sana	100	96.00%	1.0000	0.9600	0.9796
Soya Enferma	100	100.00%	0.9615	1.0000	0.9804
Global	**200**	**98.00%**	**—**	**—**	**—**

Nota. *Evaluado sobre 200 imágenes independientes del pipeline. Hiperparámetros: 60 épocas, lote=16, LR=0.00001.*

La Tabla 4 presenta la matriz de confusión del Modelo 1. De 100 imágenes sanas, 96 fueron correctamente clasificadas y 4 se confundieron con enfermas. Las 100 imágenes enfermas fueron todas identificadas correctamente.

Tabla 4 Matriz de confusión del Modelo 1.

Real \ Predicho	Soya Sana	Soya Enferma	Total
Soya Sana	96	4	100

Real \ Predicho	Soya Sana	Soya Enferma	Total
Soya Enferma	0	100	100

Nota. *Valores absolutos. La diagonal principal indica clasificaciones correctas.*

Estos resultados son consistentes con los reportados por Teachable Machine durante el entrenamiento, donde el modelo mostró 0.95 de accuracy para la clase healthy y 0.99 para diseased en la validación interna (150 muestras/clase). Las Figuras 1 y 2 muestran la matriz de confusión y las curvas de entrenamiento del Modelo 1 en la plataforma.

Figura 1.

Precisión por clase y matriz de confusiones del Modelo 1 en Teachable Machine.

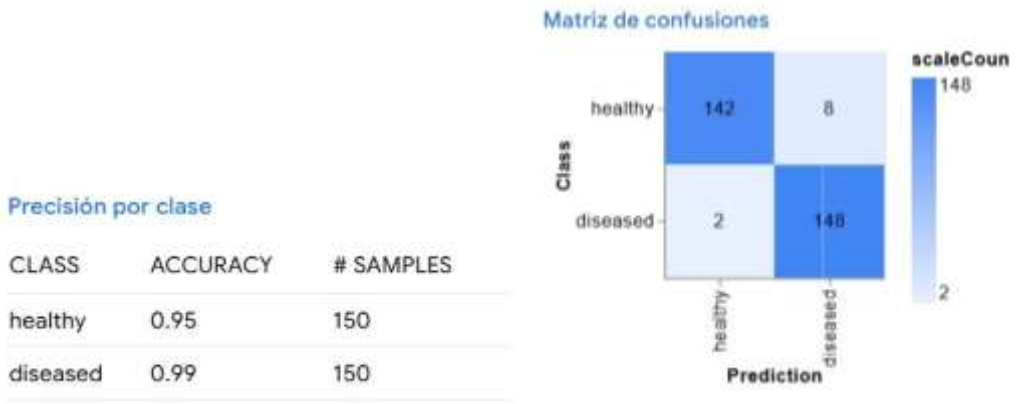

Nota. *Captura de pantalla de Teachable Machine (Google).*

Figura 2.

Curvas de precisión y pérdida por época del Modelo 1 en Teachable Machine (60 épocas, LR=0.00001).

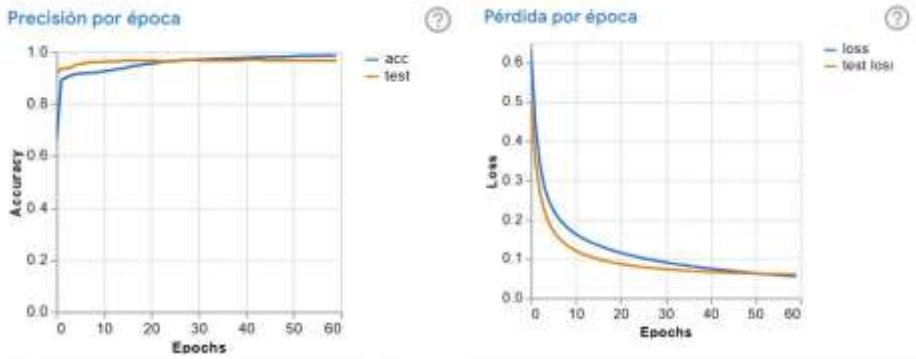

Nota. *Captura de pantalla de Teachable Machine (Google).*

Las curvas de aprendizaje (Figura 2) muestran convergencia estable desde la época 20, con las curvas de entrenamiento y validación muy próximas entre sí, lo que indica que los hiperparámetros seleccionados son adecuados y no hay sobreajuste.

Modelo 2: Clasificación del Tipo de Patógeno

La Tabla 5 presenta los resultados del Modelo 2. La exactitud global fue del 95.09% sobre 350 imágenes de prueba (70 por clase), con variación entre clases: desde 90.00% en virales hasta 100.00% en roya y plagas/insectos.

Tabla 5 Métricas de evaluación del Modelo 2 (Clasificación del tipo de patógeno).

Clase	Imgs. test	Accuracy	Precisión	Recall	F1-Score
Bacterianas	70	91.18%	0.9841	0.9118	0.9466
Fúngicas	70	94.29%	0.8684	0.9429	0.9041
Roya	70	100.00%	1.0000	1.0000	1.0000
Plagas e Insectos	70	100.00%	0.9459	1.0000	0.9722
Virales	70	90.00%	0.9692	0.9000	0.9333
Global	**350**	**95.09%**	**—**	**—**	**—**

Nota. *Evaluado sobre 350 imágenes (70 por clase × 5 clases). Hiperparámetros: 70 épocas, lote=16, LR=0.00001.*

La Tabla 6 muestra la matriz de confusión del Modelo 2. Los principales errores se concentran entre las clases bacterianas y fúngicas, y en virales, donde 5 imágenes se clasificaron erróneamente como fúngicas. Bevers et al. (2022) señalan que los síntomas del bacterial blight pueden confundirse con el septoria brown spot y otras enfermedades fúngicas, especialmente en etapas tempranas, lo que es consistente con estos resultados.

Tabla 6 Matriz de confusión del Modelo 2 (filas = clase real, columnas = clase predicha).

Real \ Predicho	Bact.	Fúng.	Roya	Plagas	Viral
Bacterianas	64	3	3	0	0
Fúngicas	2	66	0	0	2
Roya	0	0	70	0	0
Plagas e Insectos	0	0	0	70	0
Virales	1	5	1	0	63

Nota. *Bact. = Bacterianas, Fúng. = Fúngicas. La diagonal indica clasificaciones correctas.*

Las Figuras 3 y 4 muestran la precisión por clase y las curvas de entrenamiento del Modelo 2 en Teachable Machine.

Figura 3.

Precisión por clase y matriz de confusiones del Modelo 2 en Teachable Machine.

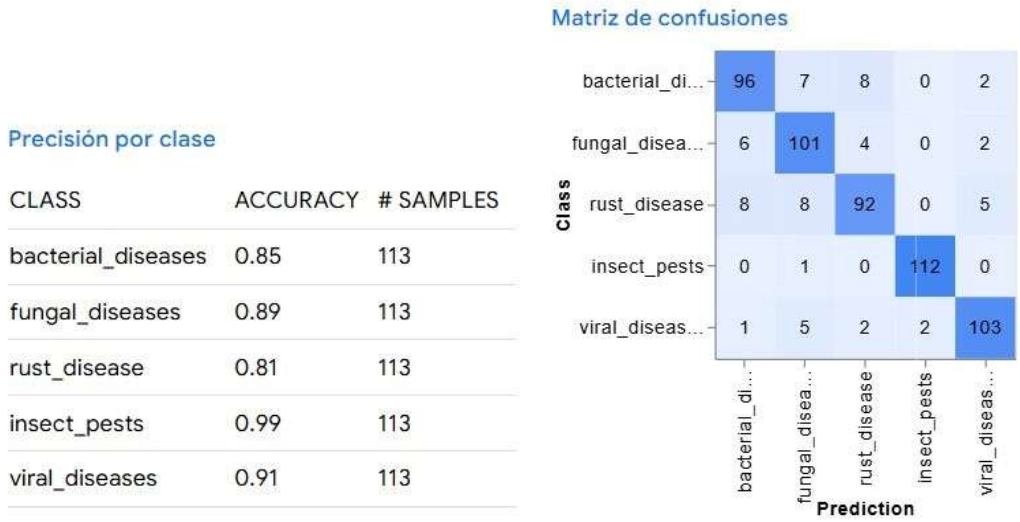

Nota. *Captura de pantalla de Teachable Machine (Google).*

Figura 4.

Curvas de precisión y pérdida por época del Modelo 2 en Teachable Machine (70 épocas, LR=0.00001).

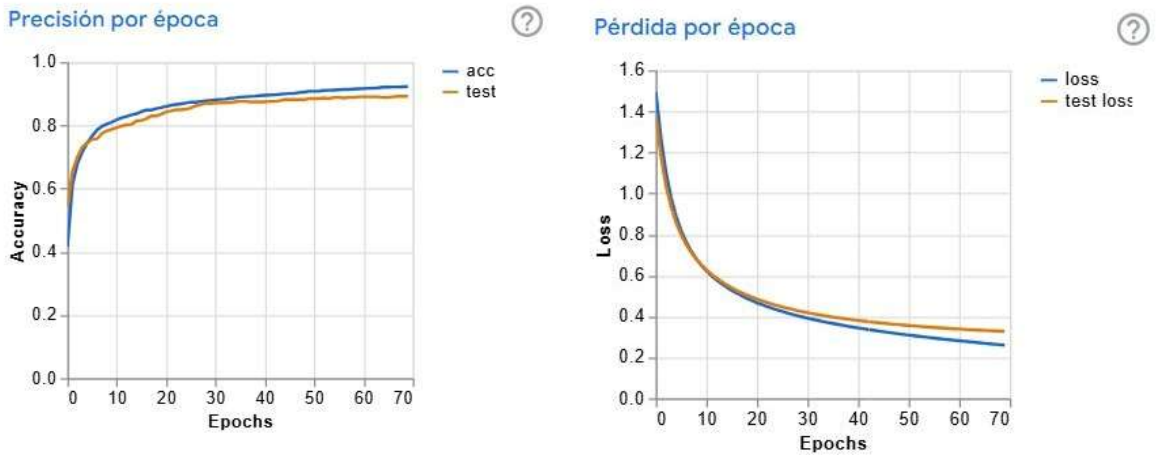

Nota. *Captura de pantalla de Teachable Machine (Google).*

Las curvas de aprendizaje del Modelo 2 (Figura 4) muestran convergencia paralela entre entrenamiento y validación sin indicios de sobreajuste. La exactitud de entrenamiento (≈92%) es ligeramente superior a la de validación (≈89%) al final de las 70 épocas, y la pérdida desciende de 1.5 a 0.27 en entrenamiento y de 1.4 a 0.33 en validación, patrón que indica una generalización adecuada dentro del dominio de los datos utilizados.

Durante el entrenamiento en Teachable Machine, el Modelo 2 reportó exactitudes de validación interna de: 0.85 (bacterianas), 0.89 (fúngicas), 0.81 (roya), 0.99 (plagas/insectos) y 0.91 (virales), con 113 muestras/clase. Los resultados del evaluador externo son superiores en todas las clases, lo que se explica porque el evaluador externo utiliza imágenes sobrantes del muestreo de los mismos datasets de entrenamiento, mientras que Teachable Machine evalúa con el 20% del conjunto de entrenamiento en su validación interna.

Conclusiones

Glycine Vision demostró ser un sistema viable para el triaje fitosanitario digital de enfermedades en soya, con una exactitud del 98.00% en la clasificación sana/enferma y del 95.09% en la identificación del tipo de patógeno sobre conjuntos de prueba independientes. El proceso en cascada permite tomar decisiones de manejo diferenciadas según el tipo de patógeno, lo cual tiene aplicabilidad directa para los productores soyeros de Santa Cruz, Bolivia.

La estrategia de combinar imágenes de campo (ASDID) con imágenes de fondo controlado (PlantVillage) para la clase sana contribuyó a reducir el domain shift en el Modelo 1. El dataset curado y el código fuente del sistema están disponibles públicamente en Hugging Face y GitHub, respectivamente.

Como limitación principal, se identificó que el rendimiento del Modelo 2 en enfermedades bacterianas es el más bajo (91.18%), posiblemente por la similitud visual con enfermedades fúngicas en etapas tempranas. A futuro, se podría explorar técnicas de data augmentation específicas para dominio, arquitecturas más robustas como EfficientNet o ResNet50 entrenadas en Google Colab, e incorporación de imágenes locales de soya de Santa Cruz para mejorar la generalización al contexto geográfico objetivo.

Referencias

Abade, A., Ferreira, P. A., & de Barros Vidal, F. (2023). Improving deep learning classifiers performance via preprocessing and class imbalance approaches in a plant disease detection pipeline. Agronomy, 13(3), 887. https://doi.org/10.3390/agronomy13030887

Barbedo, J. G. A. (2018). Impact of dataset size and variety on the effectiveness of deep learning and transfer learning for plant disease classification. Computers and Electronics in Agriculture, 153, 46-53. https://doi.org/10.1016/j.compag.2018.08.013

Bevers, N., Sikora, E. J., Hardy, N. B., & Conner, K. N. (2022). Soybean disease identification using original field images and transfer learning with convolutional neural networks. Computers and Electronics in Agriculture, 203, 107449. https://doi.org/10.1016/j.compag.2022.107449

Carney, M., Webster, B., Alvarado, I., Phillips, K., Howell, N., Griffith, J., ... & Chen, A. (2020). Teachable Machine: Approachable web-based tool for exploring machine learning classification. Proceedings of CHI Extended Abstracts, ACM.

Chen, J., Chen, J., Zhang, D., Sun, Y., & Nanehkaran, Y. A. (2020). Using deep transfer learning for image-based plant disease identification. Multimedia Tools and Applications, 79, 11617-11635. https://doi.org/10.1007/s11042-020-09669-w

Elfatimi, E., Eryigit, R., & Elfatimi, L. (2022). Beans leaf diseases classification using MobileNet models. IEEE Access, 10, 9471-9482. https://doi.org/10.1109/ACCESS.2022.3142817

Ferentinos, K. P. (2018). Deep learning models for plant disease detection and diagnosis. Computers and Electronics in Agriculture, 145, 311-318. https://doi.org/10.1016/j.compag.2018.01.009

Howard, A. G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., ... & Adam, H. (2017). MobileNets: Efficient convolutional neural networks for mobile vision applications. arXiv preprint arXiv:1704.04861.

Jakhar, D., & Borah, M. D. (2025). Effective near-duplicate image detection using perceptual hashing and deep learning. Information Processing & Management, 62(1). https://doi.org/10.1016/j.ipm.2024.103943

Kim, S. Y., Choe, E. K., Shim, S. J., & Seo, J. S. (2023). Stratified random sampling for machine learning prediction of surgical outcomes. Scientific Reports, 13, 4890.

Malahina, A. B., Putra, R. A., & Krismadinata, K. (2024). Teachable Machine: Optimization of herbal plant image classification based on epoch value, batch size and learning rate. Journal of Applied Data Sciences, 5(1).

Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. Frontiers in Plant Science, 7, 1419. https://doi.org/10.3389/fpls.2016.01419

Nazki, H., Lee, J., Yoon, S., & Park, D. S. (2020). Addressing class imbalance in image-based plant disease detection. IEEE International Conference on Bioinformatics and Biomedicine (BIBM).

Park, J., Kim, D. W., Kim, H., & Chung, Y. S. (2023). A three-step approach for classification of plant disease, crop type, and disease severity. Scientific Reports, 13, 12564.

Pertuz, S., Puig, D., & Garcia, M. A. (2013). Analysis of focus measure operators for shape-from-focus. Pattern Recognition, 46(5), 1415-1432.

Rani, R., & Gowrishankar, S. (2023). Pathogen-based classification of plant diseases: A deep transfer learning approach for intelligent support systems. IEEE Access, 11, 64476-64489. https://doi.org/10.1109/ACCESS.2023.3284245

Shrivastava, V. K., Soni, R. K., & Jain, S. (2026). Guava disease classification using Google Teachable Machine. Plant Science Today, 13(1). https://doi.org/10.14719/pst.11037

Sobre el autor

Alejandro Ramirez Vallejos es estudiante de Ingeniería de Software de la Universidad Católica Boliviana, sede Santa Cruz. Se ha desarrollado el siguiente documento para un examen de la asignatura de Inteligencia Artificial.

Financiamiento de la investigación

Con recursos propios.

Declaración de intereses

Declara no tener ningún conflicto de intereses que puedan haber influido en los resultados obtenidos o las interpretaciones propuestas.

Declaración de consentimiento informado

El estudio se realizó respetando el Código de ética y buenas prácticas editoriales de publicación.

Derechos de uso

Copyright© 2026 por Alejandro Ramirez Vallejos. Este texto está protegido por la Licencia Creative Commons Atribución 4.0 Internacional.