

Artículo científico

Detección móvil de enfermedades y severidad foliar en soya

Mobile detection of foliar diseases and severity in soybean

Edgar Jaldín Torrico

Doctorado en Ciencias de la Computación
Universidad Autónoma Gabriel René
Moreno, Santa Cruz, Bolivia

 <https://orcid.org/0009-0005-5329-4908>
edgarjaldintorrico@gmail.com

Alejandro Ramírez Vallejos

Estudiante de Ingeniería de Software
Universidad Católica Boliviana, Santa Cruz,
Bolivia

 <https://orcid.org/0009-0009-1517-6838>
alejandro.ramirez.v@ucb.du.bo

Recibido: 09/08/2026

Resumen

El objetivo de esta investigación fue desarrollar y evaluar Glycine Vision, un sistema móvil de apoyo al triaje fitosanitario en soya (*Glycine max*) que detecta enfermedades foliares y estima su severidad con inferencia local. Se aplicó un diseño experimental cuantitativo con una arquitectura de tres etapas: segmentación hoja–fondo (U-Net con codificador ResNet50) y dos clasificadores en cascada de doble entrada, sana/enferma (EfficientNetB1) y de patógeno en cinco categorías (EfficientNetB0). La severidad se cuantificó como porcentaje de área foliar afectada mediante reglas de color en CIELab. Los modelos se entrenaron con transferencia de aprendizaje, normalización Shades-of-Gray y aumento de datos, y se exportaron a TensorFlow Lite en variantes float32 e int8. Sobre conjuntos de prueba independientes, la segmentación alcanzó recall de hoja de 0.977 (Dice 0.885); el estado sanitario, exactitud de 0.980 con recall perfecto en la clase enferma; y el patógeno, exactitud de 0.969 y F1 macro de 0.968. Frente a un evaluador experto ($n = 60$), la severidad concordó estrechamente ($r = 0.967$; MAE 5.7 %). El sistema es una herramienta preliminar de apoyo al monitoreo foliar, no un sustituto del criterio agronómico, y requiere validación local adicional.

Palabras clave: visión por computadora, enfermedades de soya, segmentación semántica, severidad foliar, inferencia en dispositivos móviles.

Abstract

The objective of this research was to develop and evaluate Glycine Vision, a mobile decision-support tool for phytosanitary triage in soybean (*Glycine max*) that detects foliar diseases and estimates their severity with on-device inference. A quantitative experimental design was applied, with a three-stage architecture: leaf–background segmentation (U-Net with a ResNet50 encoder) and two

cascaded dual-input classifiers, healthy/diseased (EfficientNetB1) and pathogen across five categories (EfficientNetB0). Severity was quantified as the percentage of affected leaf area using CIELab color rules. Models were trained with transfer learning, Shades-of-Gray normalization and data augmentation, and exported to TensorFlow Lite in float32 and int8 variants. On independent test sets, segmentation reached a leaf recall of 0.977 (Dice 0.885); the health classifier, an accuracy of 0.980 with perfect recall on the diseased class; and the pathogen classifier, an accuracy of 0.969 and macro F1 of 0.968. Against an expert evaluator ($n = 60$), severity agreed closely ($r = 0.967$; MAE 5.7 %). The system is a preliminary tool to support foliar monitoring, not a substitute for agronomic judgment, and requires additional local validation.

Keywords: computer vision, soybean diseases, semantic segmentation, foliar severity, edge inference.

Introducción

La soya (*Glycine max*) es uno de los cultivos de mayor importancia económica de Bolivia, con una producción cercana a 3.7 millones de toneladas en la campaña 2024/25, concentrada en más del 95 % en el departamento de Santa Cruz (USDA-FAS, 2025). Las enfermedades foliares (roya asiática, mancha bacteriana, mosaicos virales, enfermedades fúngicas y plagas) pueden causar pérdidas del 20 % al 80 % si no se detectan a tiempo (Faye et al., 2023). La roya asiática, presente desde 2003, se desencadena en horas con 15–24 °C y humedad foliar, condiciones frecuentes en Santa Cruz (Hossain et al., 2024).

El diagnóstico tradicional depende de inspección visual o laboratorio, procedimientos costosos, lentos y poco accesibles, y la evaluación de severidad es subjetiva (Bock et al., 2022). La visión por computadora y el aprendizaje profundo ofrecen alternativas objetivas y escalables (Faye et al., 2023; Goshika et al., 2023): la segmentación semántica delimita la hoja con U-Net (Ronneberger et al., 2015); la clasificación por transferencia con ResNet (He et al., 2016) o EfficientNet (Tan & Le, 2019) logra alta exactitud con datos moderados; y la severidad, como porcentaje de área afectada, es el descriptor fitopatométrico central, obtenible por análisis de color (Bock et al., 2022; da Silva et al., 2022).

Este trabajo cierra la brecha entre el rendimiento en laboratorio y el desempeño en campo con una herramienta que funciona en el teléfono del productor, sin conectividad

y con criterios trazables, incorporando normalización cromática, aumento de datos y segmentación para tolerar la captura con smartphone. El objetivo fue desarrollar y evaluar un sistema de apoyo al triaje fitosanitario en soya que detecte enfermedades foliares y estime su severidad con inferencia local, con cuatro objetivos específicos: segmentar la hoja de forma robusta, clasificar el estado sanitario y el patógeno en cascada, cuantificar la severidad de forma interpretable y desplegar el sistema cuantizado para uso sin conexión.

Metodología

Se adoptó un enfoque cuantitativo con diseño experimental reproducible: preparación de datos, entrenamiento de segmentación y de los dos clasificadores en cascada, evaluación independiente y exportación móvil. El dataset curado y el código están disponibles en Hugging Face (Jaldín Torrico & Ramírez Vallejos, 2026c) y en el repositorio del proyecto (Jaldín Torrico & Ramírez Vallejos, 2026a).

Población y Muestra

Se integraron ocho fuentes públicas de imágenes de hojas de soya, combinando campo real y fondo controlado para reducir el desplazamiento de dominio; el detalle de las fuentes, sus licencias y el proceso de curación se documentan en la tarjeta del dataset (Jaldín Torrico & Ramírez Vallejos, 2026c).

Las enfermedades se agruparon en cinco categorías por patógeno: bacterianas, fúngicas, roya, virales y plagas/insectos. El pipeline aplicó filtros de calidad (apertura válida, resolución mínima 224×224 px, RGB) y deduplicación por MD5 y hash perceptual (pHash) con registro por tarea, procesando el entrenamiento antes que la prueba para evitar la fuga entrenamiento–prueba. Con semilla fija (42) se definieron conjuntos 80/20 y un test independiente (100 imágenes/clase sanitario, 70/clase patógeno). Para segmentación se fusionaron máscaras COCO propias (Roboflow) y SoyCotton (Segreto et al., 2026) como una única clase hoja, con partición 75/25 y 15 % de validación.

Herramientas Tecnológicas

El entrenamiento se realizó en Google Colab (GPU) con TensorFlow/Keras, OpenCV, Albumentations, scikit-learn y pycocotools; el etiquetado en Roboflow. El despliegue

emplea TensorFlow Lite, una app Flutter y un servicio opcional FastAPI/Docker; el clima se integra vía Open-Meteo.

Proceso Metodológico

Modelo de segmentación (M_seg). U-Net con codificador ResNet50 preentrenado en ImageNet (He et al., 2016; Ronneberger et al., 2015), entrada 256×256 px y dos clases (fondo/hoja); solo delimita la hoja y delega estado, patógeno y severidad a etapas posteriores. La referencia experta fusionó máscaras COCO propias (Roboflow) y SoyCotton (Segreto et al., 2026). La pérdida combinó entropía cruzada y Dice; la métrica principal fue el recall de hoja. Se entrenó en dos fases con parada temprana y posprocesamiento de mayor componente conexo.

Clasificadores en cascada de doble entrada. M1 (EfficientNetB1, 240×240 px) determina sana/enferma; M2 (EfficientNetB0, 224×224 px) clasifica el patógeno en cinco categorías con softmax de etiqueta única. Ambos reciben imagen original y hoja aislada (fondo negro por la máscara de M_seg) mediante un codificador compartido cuyos vectores se concatenan antes de la cabeza. Se emplearon transferencia de aprendizaje (Tan & Le, 2019), aumento con Albumentations y promediado exponencial de pesos (EMA); como pérdida, focal binaria balanceada en M1 y entropía cruzada con suavizado de etiquetas en M2.

Normalización cromática. En entrenamiento e inferencia se aplicó Shades-of-Gray (Minkowski $p = 6$, ganancia acotada a $[0.6, 1.6]$) (Finlayson & Trezzi, 2004), con fórmula idéntica en ambos para garantizar invariancia a la iluminación y paridad.

Estimación de severidad por color (CIELab). Se cuantificó como porcentaje de área foliar afectada (Bock et al., 2022), dentro de la región segmentada y en CIELab por su uniformidad perceptual (da Silva et al., 2022). Cada píxel foliar se clasificó como sano, clorótico, necrótico o defoliado mediante umbrales sobre L^* , a^* y b^* (detallados en el repositorio); la severidad agregada es el cociente entre área sintomática y área foliar esperada, y se activa solo si M1 clasifica la hoja como enferma. Niveles: mínima ($< 5\%$), leve ($5\text{--}15\%$), moderada ($15\text{--}35\%$), severa ($35\text{--}60\%$) y crítica ($\geq 60\%$).

Despliegue e inferencia local. Los tres modelos se exportaron a TensorFlow Lite en variantes float32 e int8 para ejecución sin conexión. La configuración desplegada,

idéntica en la aplicación y en el servicio de respaldo, emplea el segmentador y el clasificador de estado sanitario cuantizados a int8 y el clasificador de patógeno en float32; la elección se sustenta en la evaluación de las variantes exportadas (Tabla 4). La app Flutter implementa el flujo completo (segmentación → hoja aislada → M1 → M2 → severidad → superposición) y genera recomendaciones según enfermedad, severidad y clima sobre una base de conocimiento agronómico; las dosis y sus fórmulas se detallan en el repositorio. Los modelos entrenados, en sus variantes float32 e int8, se publican en Hugging Face (Jaldín Torrico & Ramírez Vallejos, 2026b).

La decisión y la intensidad del tratamiento siguen el umbral de acción del manejo integrado: el sistema consulta Open-Meteo (temperatura, humedad, precipitación, punto de rocío) y ajusta la recomendación (sube o baja un nivel, adelanta la aplicación ante lluvia reciente, evita las horas de mayor radiación) y verifica incompatibilidades. Son orientativas y no sustituyen el criterio agronómico (véase Uso responsable).


Evaluación

M1 y M2 se evaluaron sobre el test independiente con la misma doble entrada del entrenamiento (exactitud, precisión, recall, F1, soporte y matrices de confusión, además del error de calibración esperado y máximo y el puntaje de Brier); M_seg, sobre el 25 % held-out de las máscaras COCO (recall de hoja, Dice, IoU). Una validación de uso comparó, sobre 60 hojas (10 por categoría, un evaluador), la severidad y el patógeno de la app frente al experto, con la etiqueta del dataset como verdad de campo; la severidad con Pearson, CCC, MAE, RMSE y Bland-Altman, y el patógeno con exactitud, F1 macro y McNemar.

La Figura 1 resume el flujo completo del sistema, desde la captura hasta la salida interpretable.

Figura 1.

Diagrama de Actividad del Sistema: Normalización Cromática, Segmentación Hoja–Fondo, Clasificación en Cascada y Estimación de Severidad por CIELab.



Resultados

Modelo de Segmentación Hoja–Fondo (M_seg)

La Tabla 1 resume el desempeño de los tres modelos. M_seg, sobre el 25 % held-out de las máscaras expertas COCO, alcanzó recall de hoja de 0.977, Dice de 0.885 e IoU de 0.808 en un conjunto con doseles densos y fondos de campo exigentes.

Tabla 1

Desempeño de los Modelos Sobre Conjuntos de Prueba Independientes (IC 95 % por bootstrap).

Modelo	Métrica	Valor	IC 95 %
M_seg (U-Net ResNet50)	Recall hoja (Dice; IoU)	0.977 (0.885; 0.808)	—
M1 (EfficientNetB1)	Exactitud (recall enferma)	0.980 (1.000)	0.960–0.995
M2 (EfficientNetB0)	Exactitud / F1 macro	0.969 / 0.968	0.949–0.986
M2 — F1 por clase	bact / fúng / plag / roya / vir	0.950 / 0.920 / 0.986 / 0.986 / 1.000	—

Modelo 1: Estado Sanitario (Sana/Enferma)


M1 (Tabla 1) alcanza exactitud de 0.980 (IC 95 %: 0.960–0.995) y recall perfecto (1.000) en la clase enferma, clave en triaje pues los falsos negativos (enfermas dadas como sanas) son el error de mayor costo agronómico.

Modelo 2: Tipo de Patógeno

M2 (Tabla 1) logra exactitud global de 0.969 (IC 95 %: 0.949–0.986) y F1 macro de 0.968 sobre las cinco clases. La mayor confusión residual es fúngicas (F1 = 0.920), por su similitud con bacterianas y roya tempranas (Figura 2).

Figura 2.

Matriz de Confusión del Modelo 2.



Flujo Integrado y Severidad

La Figura 3 ilustra el flujo: M_seg delimita la hoja, M1 determina el estado, M2 (si está enferma) identifica el patógeno y el análisis CIELab produce la superposición de tres estados con el porcentaje de severidad, con trazabilidad visual entre la región atribuida y el síntoma.

Figura 3.

Ejemplo Cualitativo del Flujo de Procesamiento: Imagen Original, Hoja Segmentada, Superposición de Tres Estados.



Validación Frente al Criterio Experto

Se evaluaron 60 hojas (10 por categoría) registrando la severidad y el patógeno de la app y del experto; la etiqueta del dataset fue la verdad de campo del patógeno, una limitación del contraste (véase Limitaciones).

Severidad. La concordancia con el experto fue alta (Tabla 2): $r = 0.967$, $CCC = 0.941$, $MAE = 5.7 \%$ y $RMSE = 7.4 \%$. El Bland-Altman arrojó un sesgo de -5.0% y límites de acuerdo de $[-15.8 \%, 5.9 \%]$; el 83.3 % quedó dentro de ± 10 puntos y el 100 % dentro de ± 20 (Figura 4).

Patógeno. La app alcanzó exactitud de 0.950 (F1 macro = 0.952) y el experto, 0.867 (F1 macro 0.872) frente a la verdad de campo. En los discordantes, la app acertó en cinco que el experto erró, sin casos inversos; McNemar no alcanzó significancia ($p = 0.0625$), interpretable como desempeño comparable con tendencia favorable no concluyente por el tamaño de muestra.


Tabla 2

Concordancia de la Severidad Estimada por la Aplicación Frente al Criterio Experto (n = 60).

Métrica	Valor
Pearson r	0.967
CCC de Lin	0.941
MAE (%)	5.7
RMSE (%)	7.4
Sesgo medio Bland-Altman (%)	-5.0
Límites de acuerdo 95 % (%)	[-15.8, 5.9]
Dentro de ± 10 %	83.3 %
Dentro de ± 20 %	100 %

Figura 4.

Severidad Estimada por la Aplicación Frente al Criterio Experto: Dispersión con Línea de Identidad y Análisis de Bland-Altman.



Calibración de las probabilidades. Como la aplicación muestra la confianza del modelo al usuario, se evaluó su fiabilidad sobre el test independiente. Ambos clasificadores resultaron bien calibrados (ECE inferior a 0.05): M1 obtuvo ECE de 0.011 y Brier de 0.016 (confianza 0.986 frente a exactitud 0.980, ligeramente sobreconfiado) y M2, ECE de 0.039 y Brier de 0.049 (confianza 0.935 frente a 0.969, subconfiado), sesgo conservador preferible en triaje. El error máximo (0.63 y 0.55) se concentra en intervalos de baja confianza con muy pocas observaciones.

Despliegue Móvil y Cuantización

La cuantización int8 reduce el tamaño de los modelos unas cuatro veces respecto a float32. La Tabla 3 reporta parámetros, MACs y tamaño en float32 e int8, independientes del hardware. El costo en dispositivo se midió con la herramienta oficial benchmark_model de TensorFlow Lite sobre un Xiaomi 2203129G (gama media), con las variantes int8, cuatro hilos de CPU, diez ejecuciones de calentamiento y cincuenta de medición: la latencia media fue de 126 ms (M_seg), 19 ms (M1) y 12 ms (M2), con picos de memoria de 120, 54 y 40 MB; el flujo en cascada suma alrededor de 157 ms por hoja. Estas cifras corresponden a las variantes int8 y no a la configuración mixta de la aplicación evaluada.

Tabla 3

Costo Computacional por Modelo (Métricas Independientes del Hardware): Parámetros, MACs y Tamaño en float32 e int8.

Modelo	Parámetros (M)	MACs (G)	Tamaño float32 (MB)	Tamaño int8 (MB)
M_seg (U-Net ResNet50)	43.95	17.76	175.4	44.7
M1 (EfficientNetB1)	7.24	1.42	28.8	9.3
M2 (EfficientNetB0)	4.72	0.80	18.7	6.1

Efecto de la Exportación y la Cuantización

La conversión a TensorFlow Lite en float32 reproduce exactamente el desempeño de los modelos Keras, lo que verifica la fidelidad de la exportación. La cuantización a enteros de 8 bits, en cambio, tiene un costo desigual: es prácticamente nulo en el clasificador de estado sanitario y apreciable en el de patógeno (Tabla 4). Por ello la configuración desplegada cuantiza el segmentador y M1, y conserva M2 en float32, con lo que la exactitud reportada corresponde a los modelos efectivamente desplegados.

Tabla 4

Desempeño de las Variantes Exportadas Sobre el Test Independiente: Keras, TensorFlow Lite float32 y TensorFlow Lite int8.

Modelo	Variante	Tamaño (MB)	Exactitud	F1 macro	Δ F1
M1	Keras	63.3	0.980	0.980	—
M1	TFLite float32	28.8	0.980	0.980	0.000
M1	TFLite int8	9.4	0.975	0.975	-0.005
M2	Keras	50.7	0.969	0.968	—

M2	TFLite float32	18.7	0.969	0.968	0.000
M2	TFLite int8	6.2	0.929	0.928	-0.040

Baselines y Ablación por Componentes

El estudio de ablación (Tabla 5) desmonta un componente a la vez desde la configuración completa, con el presupuesto del modelo final, la misma partición y tres semillas. El aislamiento de la hoja mediante M_seg es el único componente cuyo aporte supera la variabilidad entre semillas; sustituir esa entrada por la imagen cruda resulta incluso inferior a usar una sola entrada, de modo que el beneficio proviene de la información complementaria de la hoja aislada y no de las dos ramas en sí. Shades-of-Gray y el promediado de pesos no mejoran la exactitud en este test, coherente en el primer caso con su propósito de robustez ante iluminación variable, no medida aquí. Una verificación independiente al mismo presupuesto, con una sola semilla, contrastó la configuración completa (0.980) con un EfficientNetB0 de una sola entrada sobre la imagen cruda (0.963); por tratarse de una única repetición, esa diferencia no es separable de la variabilidad entre semillas observada en la ablación.

Tabla 5

Ablación por Componente al Presupuesto Completo (20 + 45 Épocas, Datos Completos, Tres Semillas).

Configuración	F1 macro (media $\pm$ DE)	Δ F1
Completa (doble entrada, M_seg, SoG, EMA)	0.969 $\pm$ 0.005	—
Sin doble entrada (una sola entrada)	0.965 $\pm$ 0.006	-0.004
Sin hoja aislada (segunda entrada cruda)	0.958 $\pm$ 0.003	-0.011
Sin Shades-of-Gray	0.973 $\pm$ 0.007	+0.004
Sin EMA	0.973 $\pm$ 0.005	+0.004

Discusión

Validez y robustez

La validez regional es plausible pero no demostrada. Como el conjunto combina ocho fuentes sin partición por procedencia, las métricas obtenidas deben interpretarse como desempeño interno del corpus y no como evidencia de generalización regional: imágenes distintas de una misma planta, sesión o condición de captura pueden quedar repartidas entre entrenamiento y prueba. Aunque las fuentes incluyen campo real (ASDID) y las

cinco categorías corresponden a Santa Cruz, donde *P. pachyrhizi* circula desde 2003 (Hossain et al., 2024), variedades y condiciones locales pueden introducir desplazamiento de dominio, por lo que se requiere un test con imágenes propias. La robustez ante la captura no controlada se apoya en Shades-of-Gray (Finlayson & Trezzi, 2004), el aumento de datos y la segmentación con hoja aislada.

La inferencia se ejecuta en el dispositivo sin conectividad, lo que preserva la privacidad al no transmitir imágenes. La severidad CIELab ofrece trazabilidad visual y desagrega clorosis, necrosis y defoliación (MAE 5.7 % vs. experto), y la integración de clima (Open-Meteo) ajusta la urgencia sin confirmar el diagnóstico.

Uso Responsable de las Recomendaciones Fitosanitarias

El sistema puede influir en decisiones de aplicación de fitosanitarios, por lo que sus recomendaciones son orientativas, no prescriptivas: no reemplazan al agrónomo ni al diagnóstico de laboratorio; las dosis deben verificarse contra la etiqueta y la normativa local (SENASAG); y deben considerarse el riesgo ambiental, la resistencia y la seguridad del aplicador.

Comparación con la literatura

Los resultados concuerdan con la literatura reciente: la identificación por imágenes de campo y transferencia muestra desempeños elevados (Bever et al., 2022), y los modelos que combinan clasificación y evaluación de daño confirman su viabilidad (Goshika et al., 2023), con exactitudes comparables a propuestas recientes. En severidad converge con los enfoques de color en CIELab (da Silva et al., 2022) y con las mejores prácticas de estimación (Bock et al., 2022). El aporte central es integrar segmentación, clasificación en cascada y severidad en un único flujo con inferencia local.

Limitaciones

Falta validación con imágenes propias de Santa Cruz. La validación experta usó 60 hojas y un evaluador, sin acuerdo inter-evaluador y con McNemar no significativo ($p = 0.0625$), por lo que el contraste app-experto es orientativo. La verdad de campo del patógeno proviene de la etiqueta del dataset, no de laboratorio. Aunque la deduplicación combina MD5 y pHash sin fuga entrenamiento–prueba, no existe partición por procedencia, de modo que las métricas reflejan desempeño interno del corpus. El conjunto curado

combina fuentes con licencias mixtas, algunas no especificadas y una de tipo no comercial, por lo que se comparte con fines de investigación académica y no debe asumirse reutilizable comercialmente. Los umbrales CIELab son fijos y requieren recalibración; el aporte de la normalización cromática y del promediado de pesos no pudo verificarse fuera del dominio de entrenamiento; y el desempeño puede degradarse bajo iluminación extrema u oclusión severa.

Conclusiones

Se desarrolló y evaluó Glycine Vision, un sistema modular de apoyo al triaje fitosanitario en soya que integra segmentación hoja–fondo, clasificación en cascada de doble entrada y estimación interpretable de severidad por CIELab con inferencia local. Sobre test independientes alcanzó recall de hoja de 0.977, exactitud de 0.980 en el estado sanitario (recall perfecto en la clase enferma) y 0.969 en el patógeno (F1 macro 0.968); frente al experto, la severidad concordó ($r = 0.967$; MAE 5.7 %) y el diagnóstico fue comparable (0.95 vs. 0.87; McNemar $p = 0.0625$). Un estudio de ablación al presupuesto completo identificó el aislamiento de la hoja mediante M_seg como el componente de mayor aporte a la clasificación del patógeno.

La aplicabilidad operativa queda delimitada a un uso de apoyo al monitoreo foliar, no como sustituto del criterio profesional; su adopción para diagnóstico y manejo requiere, previamente, validación local en Santa Cruz, contraste con varios expertos y verificación agronómica y regulatoria. Como líneas futuras se plantea incorporar imágenes locales, ampliar la validación con acuerdo inter-evaluador, reforzar la partición por fuente y ampliar la caracterización en dispositivos de gama baja.

Referencias

- Bevers, N., Sikora, E. J., Hardy, N. B., & Conner, K. N. (2022). Soybean disease identification using original field images and transfer learning with convolutional neural networks. *Computers and Electronics in Agriculture*, 203, 107449. <https://doi.org/10.1016/j.compag.2022.107449>
- Bock, C. H., Chiang, K.-S., & Del Ponte, E. M. (2022). Plant disease severity estimated visually: A century of research, best practices, and opportunities for

improving methods and practices to maximize accuracy. *Tropical Plant Pathology*, 47(1), 25–42. <https://doi.org/10.1007/s40858-021-00439-z>

da Silva, D. A., Hamawaki, C. L., Juliatti, B. C. M., Nascimento, L. dos S., Hamawaki, O. T., Borges, D. L., Juliatti, F. C., & Nogueira, A. P. O. (2022). An automatic phytopathometry system for chlorosis and necrosis severity evaluation of Asian soybean rust infection. *Computers and Electronics in Agriculture*, 192, 106542. <https://doi.org/10.1016/j.compag.2021.106542>

Faye, D., Diop, I., Mbaye, N., Dione, D., & Diedhiou, M. M. (2023). Plant disease severity assessment based on machine learning and deep learning: A survey. *Journal of Computer and Communications*, 11(9), 57–75. <https://doi.org/10.4236/jcc.2023.119004>

Finlayson, G. D., & Trezzi, E. (2004). Shades of gray and colour constancy. *Proceedings of the 12th Color Imaging Conference*, 37–41. Society for Imaging Science and Technology. <https://doi.org/10.2352/CIC.2004.12.1.art00008>

Goshika, S., Meksem, K., Ahmed, K. R., & Lakhssassi, N. (2023). Deep learning model for classifying and evaluating soybean leaf disease damage. *International Journal of Molecular Sciences*, 25(1), 106. <https://doi.org/10.3390/ijms25010106>

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778. <https://doi.org/10.1109/CVPR.2016.90>

Hossain, M. M., Sultana, F., Yesmin, L., Rubayet, M. T., Abdullah, H. M., Siddique, S. S., Bhuiyan, M. A. B., & Yamanaka, N. (2024). Understanding *Phakopsora pachyrhizi* in soybean: Comprehensive insights, threats, and interventions from the Asian perspective. *Frontiers in Microbiology*, 14, 1304205. <https://doi.org/10.3389/fmicb.2023.1304205>

Jaldín Torrico, E., & Ramírez Vallejos, A. (2026a). Glycine Vision DSS (Versión 1.0.0) [Software]. GitHub. <https://github.com/alejandroramirezucb/glycine-vision-dss>

Jaldín Torrico, E., & Ramírez Vallejos, A. (2026b). Glycine Vision: modelos de triaje fitosanitario en soya [Modelo]. Hugging Face. <https://huggingface.co/alejandroramirezucb/glycine-vision-models>

Jaldín Torrico, E., & Ramírez Vallejos, A. (2026c). Soybean image dataset

[Conjunto de datos]. Hugging Face.
https://huggingface.co/datasets/alejandroramirezucb/soybean_image_dataset

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. MICCAI 2015, 234–241.
https://doi.org/10.1007/978-3-319-24574-4_28

Segreto, T. H., Negri, J. D., Polegato, P. H., Pinheiro, J. M. H., Godoy, R. V., & Becker, M. (2026). A leaf-level dataset for soybean–cotton detection and segmentation [Conjunto de datos]. Scientific Data, 13(1), 872. <https://doi.org/10.1038/s41597-026-07092-8>

Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. ICML, PMLR 97, 6105–6114.
<https://doi.org/10.48550/arXiv.1905.11946>

United States Department of Agriculture, Foreign Agricultural Service. (2025). Bolivia: Soybean area, yield and production [Base de datos]. International Production Assessment Division.
<https://ipad.fas.usda.gov/countrysummary/Default.aspx?id=BL&crop=Soybean>

Sobre los Autores

Edgar Jaldín Torrico es doctorante en el programa de Ciencias de la Computación de la Universidad Autónoma Gabriel René Moreno; ingeniero electrónico, con Maestría en Ciencia de Datos por la Università degli Studi di Bari Aldo Moro (Italia) y Maestría en Seguridad de Redes Informáticas por la Università degli Studi Niccolò Cusano (Roma, Italia). Se desempeña como Chief Operating Officer de Inteligencia Artificial en la empresa Abisoft (Italia), donde lidera el desarrollo de algoritmos de IA, y es docente en la Universidad Católica Boliviana San Pablo (Santa Cruz de la Sierra), en asignaturas de inteligencia artificial, aprendizaje automático y visión computacional.

Alejandro Ramírez Vallejos es estudiante de Ingeniería de Software en la Universidad Católica Boliviana (Santa Cruz, Bolivia) y coautor del artículo “Algoritmos de IA en salud: evaluando precisión y ética en Bolivia” (Journal Boliviano de Ciencias, 2026).

Financiamiento de la Investigación

Con recursos propios.

Declaración de Intereses

Los autores declaran no tener conflictos de intereses que puedan haber influido en los resultados obtenidos o las interpretaciones propuestas.

Declaración de Consentimiento Informado

El estudio se realizó respetando el Código de ética y buenas prácticas editoriales de publicación.

Derechos de Uso

Copyright© 2026 por Edgar Jaldín Torrico & Alejandro Ramírez Vallejos. Este texto está protegido por la [Licencia Creative Commons Atribución 4.0 Internacional](https://creativecommons.org/licenses/by/4.0/).



Usted es libre para compartir, copiar y redistribuir el material en cualquier medio o formato y adaptar el documento, remezclar, transformar y crear a partir del material para cualquier propósito, incluso comercialmente, siempre que cumpla la condición de atribución: reconocer el crédito de manera adecuada, proporcionar un enlace a la licencia e indicar si se han realizado cambios, sin sugerir que tiene el apoyo del licenciante.